

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH



BÁO CÁO BÀI TẬP LỚN TRÍ TUỆ NHÂN TẠO

GVHD: ThS. VÕ VIỆT KHOA

Thành viên:

2351050132 - PHẠM THÀNH PHÁT

2351050209 - PHẠM THỊ MỸ XUYỀN

2351050145 - NGÔ THỊ THÚY QUYÊN

ĐỀ TÀI: HEART DISEASE CLASSIFICATION

TP. HỒ CHÍ MINH, 2026

MỤC LỤC:

LỜI CẢM ƠN.....	4
DANH MỤC TỪ VIẾT TẮT.....	5
CHƯƠNG 1: GIỚI THIỆU.....	6
1.1. Bối cảnh và Hiện trạng.....	6
1.2. Mục tiêu Dự án.....	6
1.3. Lý do Lựa chọn Mô hình và Metric.....	7
1.4. Phạm vi và Cấu trúc Báo cáo.....	7
CHƯƠNG 2: PHƯƠNG PHÁP.....	8
2. 1. Mô tả Dataset.....	8
2.2. Phân tích Dữ liệu Khám phá (EDA).....	9
2.2.1. Tổng quan Dữ liệu.....	9
2.2.2. Phân tích Missing Values.....	9
2.2.3. Phân tích Tương quan (Correlation Analysis).....	10
2.2.4. Phân tích Phân phối và Outlier.....	11
2.3. Tiền xử lý Dữ liệu (Preprocessing).....	11
2.3.1. Chiến lược Tiền xử lý.....	11
2.3.2. Chia tập Train/Test.....	12
2.3.3. Kiến trúc Pipeline scikit-learn.....	12
2.4. Feature Engineering.....	13
2.4.1. Đặc trưng 1: heart_rate_ratio – Tỷ lệ Nhịp tim đạt được.....	13
2.4.2. Đặc trưng 2: age_risk_group – Nhóm Nguy cơ theo Tuổi.....	13
2.4.3. Đánh giá hiệu quả Feature Engineering.....	13
2.5. Mô hình Machine Learning.....	14
2.5.1. Logistic Regression (Mô hình 1).....	14
2.5.2. Random Forest (Mô hình 2).....	14
2.5.3. Support Vector Machine (Mô hình 3).....	14
2.6. Theo dõi Thực nghiệm với Weights & Biases (wandb).....	15
CHƯƠNG 3: KẾT QUẢ THỰC NGHIỆM.....	15
3.1. Kết quả từng Mô hình.....	15
3.1.1. Logistic Regression.....	15

3.1.2. Random Forest – So sánh 3 Kịch bản.....	16
3.1.3. Support Vector Machine.....	16
3.2. So sánh Tổng thể Các Mô hình.....	17
3.3. Đường cong ROC và Feature Importance.....	18
3.3.1. Phân tích ROC Curve.....	18
3.3.2. Feature Importance (Random Forest).....	19
3.4. Model Persistence.....	19
CHƯƠNG 4: ỨNG DỤNG THỰC TẾ.....	20
4.1. Kiến trúc Hệ thống.....	20
4.2. Cơ sở Dữ liệu MySQL.....	21
4.3. API Endpoints.....	21
4.4. Kịch bản Sử dụng Thực tế.....	21
4.4.1. Kịch bản 1: Sàng lọc tại Phòng khám Đa khoa.....	21
4.4.2. Kịch bản 2: Theo dõi Bệnh nhân Tim mạch Mãn tính.....	22
4.5. Hạn chế và Rủi ro khi Triển khai.....	22
4.6. Video thực hiện demo project.....	23
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	23
5.1. Tổng kết Đóng góp.....	23
5.2. Hạn chế.....	23
5.3. Hướng Phát triển.....	24
TÀI LIỆU THAM KHẢO.....	24

LỜI CẢM ƠN

Đầu tiên chúng em xin gửi lời cảm ơn chân thành đến thầy Võ Việt Khoa – giảng viên hướng dẫn môn Trí tuệ Nhân tạo – đã tận tình hướng dẫn, giải đáp thắc mắc và tạo điều kiện để nhóm thực hiện bài tập này một cách thuận lợi nhất.

Chúng em cũng cảm ơn UCI Machine Learning Repository đã cung cấp dataset Heart Disease – nguồn dữ liệu lâm sàng quý giá phục vụ nghiên cứu trong đồ án. Lời cảm ơn đặc biệt gửi đến các tác giả thư viện scikit-learn, Weights & Biases và cộng đồng mã nguồn mở đã cung cấp các công cụ hỗ trợ quá trình xây dựng mô hình.

Cuối cùng, chúng em cảm ơn các bạn trong nhóm đã nỗ lực, phối hợp nhịp nhàng và trách nhiệm trong suốt quá trình thực hiện đồ án.

DANH MỤC TỪ VIẾT TẮT

Viết tắt	Giải nghĩa
ML	Machine Learning – Học máy
EDA	Exploratory Data Analysis – Phân tích dữ liệu khám phá
FE	Feature Engineering – Kỹ thuật đặc trưng
CV	Cross-Validation – Kiểm chứng chéo
LR	Logistic Regression – Hồi quy logistic
RF	Random Forest – Rừng ngẫu nhiên
SVM	Support Vector Machine – Máy vectơ hỗ trợ
AUC	Area Under Curve – Diện tích dưới đường cong ROC
ROC	Receiver Operating Characteristic Curve
API	Application Programming Interface – Giao diện lập trình ứng dụng
FE (Tech)	Frontend – Giao diện người dùng (ReactJS)
BE	Backend – Máy chủ phía sau (Flask)
DB	Database – Cơ sở dữ liệu (MySQL)
CDSS	Clinical Decision Support System – Hệ thống hỗ trợ quyết định lâm sàng
ECG	Electrocardiogram – Điện tâm đồ
wandb	Weights & Biases – Công cụ theo dõi thực nghiệm ML

CHƯƠNG 1: GIỚI THIỆU

1.1. Bối cảnh và Hiện trạng

Theo Tổ chức Y tế Thế giới (WHO), bệnh tim mạch là nguyên nhân tử vong số một trên thế giới, chiếm khoảng 17,9 triệu ca tử vong mỗi năm – tương đương 31% tổng số ca tử vong toàn cầu. Tại Việt Nam, bệnh tim mạch cũng là nguyên nhân hàng đầu gây tử vong và để lại gánh nặng y tế lớn cho xã hội.

Thách thức lớn nhất trong điều trị bệnh tim mạch là việc chẩn đoán muộn: bệnh nhân thường không có triệu chứng rõ ràng ở giai đoạn đầu, khiến bác sĩ khó phát hiện kịp thời. Các phương pháp chẩn đoán truyền thống đòi hỏi nhiều xét nghiệm chuyên sâu tốn kém, trong khi nhu cầu y tế ngày càng tăng cao. Đây chính là động lực thúc đẩy việc ứng dụng Machine Learning (ML) trong y học, đặc biệt là xây dựng các mô hình dự đoán nguy cơ bệnh tim từ các chỉ số lâm sàng cơ bản.

1.2. Mục tiêu Dự án

Dự án nhằm xây dựng một hệ thống phân loại bệnh tim mạch end-to-end với các mục tiêu cụ thể sau:

- Xây dựng mô hình ML có khả năng phân loại chính xác giữa bệnh nhân có bệnh tim và không có bệnh tim từ các chỉ số lâm sàng cơ bản.
- Ưu tiên tối ưu hóa chỉ số Recall (Độ nhạy) để hạn chế tối đa việc bỏ sót bệnh nhân có bệnh (False Negative), đồng thời duy trì Precision ở mức hợp lý nhằm tránh lãng phí tài nguyên y tế.
- Xây dựng hệ thống ứng dụng web hoàn chỉnh: Frontend (ReactJS) ↔ Backend API (Flask) ↔ AI Model ↔ Database (MySQL), cho phép bác sĩ hoặc chuyên gia y tế nhập chỉ số lâm sàng và nhận kết quả chẩn đoán ngay lập tức.

- Theo dõi và so sánh các thực nghiệm ML một cách có hệ thống bằng Weights & Biases (wandb).
- Đảm bảo tính tái lập (reproducibility) và chất lượng code theo tiêu chuẩn phần mềm thực tế.

1.3. Lý do Lựa chọn Mô hình và Metric

Lý do chọn Recall làm metric ưu tiên: Trong bối cảnh y tế, bỏ sót một bệnh nhân có bệnh tim (False Negative) có thể dẫn đến hậu quả nghiêm trọng – thậm chí tử vong – nếu không được điều trị kịp thời. Ngược lại, một báo động giả (False Positive) chỉ dẫn đến việc bệnh nhân cần làm thêm xét nghiệm xác nhận, một chi phí chấp nhận được. Do đó, Recall được đặt làm metric ưu tiên hàng đầu.

Lý do chọn ngưỡng phân loại 0.4: Thay vì ngưỡng mặc định 0.5, nhóm hạ xuống 0.4 để tăng Recall – chấp nhận một tỷ lệ báo động giả cao hơn nhằm đảm bảo không bỏ sót ca bệnh nguy hiểm. Đây là trade-off hoàn toàn hợp lý trong chẩn đoán y tế.

Lý do chọn Random Forest làm mô hình triển khai: Sau khi so sánh 3 mô hình (Logistic Regression, Random Forest, SVM), Random Forest đạt hiệu suất tổng thể tốt nhất với Recall = 0.9412, AUC = 0.9042 và F1 = 0.8533 – đáp ứng đồng thời cả ba trụ cột: an toàn y tế, độ tin cậy và tính thực tiễn.

1.4. Phạm vi và Cấu trúc Báo cáo

Báo cáo được tổ chức theo 5 chương chính: Giới thiệu (Chương 1), Phương pháp (Chương 2), Kết quả Thực nghiệm (Chương 3), Ứng dụng Thực tế (Chương 4), và Kết luận & Hướng phát triển (Chương 5). Mã nguồn và notebook phân tích đầy đủ có thể truy cập tại kho lưu trữ GitHub của nhóm.

CHƯƠNG 2: PHƯƠNG PHÁP

2. 1. Mô tả Dataset

Tên dataset: UCI Heart Disease Repository

Nguồn: <https://archive.ics.uci.edu/dataset/45/heart+disease>

Quy mô: 920 bệnh nhân từ 4 bệnh viện: Cleveland (Mỹ), Hungary, Switzerland và VA Long Beach (Mỹ)

Biến mục tiêu: Cột 'num' gốc có giá trị từ 0 đến 4 (0 = không bệnh, 1–4 = mức độ bệnh). Nhóm chuyển đổi thành nhị phân: target = 0 (không bệnh) và target = 1 (có bệnh).

Bảng 2.1 – Mô tả các biến trong dataset:

Tên cột	Kiểu dữ liệu	Phân loại	Ý nghĩa lâm sàng
age	Numerical	Liên tục	Tuổi bệnh nhân (năm)
sex	Categorical	Phân loại	Giới tính (Male/Female)
cp	Categorical	Phân loại	Loại đau ngực (typical angina, atypical, non-anginal, asymptomatic)
trestbps	Numerical	Liên tục	Huyết áp lúc nghỉ (mmHg)
chol	Numerical	Liên tục	Cholesterol huyết thanh (mg/dl)
fbs	Categorical	Nhị phân	Đường huyết lúc đói > 120 mg/dl (True/False)
restecg	Categorical	Phân loại	Kết quả điện tâm đồ lúc nghỉ
thalch	Numerical	Liên tục	Nhịp tim tối đa đạt được (bpm)
exang	Categorical	Nhị phân	Đau ngực khi gắng sức (Y/N)

oldpeak	Numerical	Liên tục	ST depression khi gắng sức so với lúc nghỉ
slope	Categorical	Phân loại	Độ dốc đoạn ST (upsloping/flat/downsloping)
ca	Numerical	Rời rạc	Số mạch vành chính chụp được (0–3)
thal	Categorical	Phân loại	Tình trạng thiếu máu cơ tim (normal/fixed/reversable)

2.2. Phân tích Dữ liệu Khám phá (EDA)

2.2.1. Tổng quan Dữ liệu

Dataset gồm 920 hàng và 14 cột (sau khi thêm cột target). Phân phối biến mục tiêu tương đối cân bằng: 411 bệnh nhân không mắc bệnh (44.7%) và 509 bệnh nhân mắc bệnh (55.3%). Sự cân bằng này giúp mô hình học ổn định trên cả hai lớp mà không cần áp dụng kỹ thuật xử lý mất cân bằng phức tạp.

2.2.2. Phân tích Missing Values

Dataset có tình trạng thiếu dữ liệu đáng kể ở một số cột.

Bảng 2.2-Tổng hợp tỷ lệ missing value theo từng cột:

Cột	Tỷ lệ Missing (%)	Nhận xét
ca	66.41%	Bị loại khỏi tập đặc trưng – xét nghiệm chuyên sâu
thal	52.83%	Bị loại khỏi tập đặc trưng – xét nghiệm chuyên sâu

slope	33.6%	Điền bằng Mode (most_frequent)
fbs	9.8%	Điền bằng Mode (most_frequent)
oldpeak	6.7%	Điền bằng Median
trestbps	6.4%	Điền bằng Median
Các cột khác	< 5%	Điền tương ứng theo chiến lược chung

Lưu ý: Cột ca và thal bị loại không chỉ vì tỷ lệ missing cao, mà còn vì chúng là kết quả của các xét nghiệm xâm lấn chuyên sâu (chụp mạch, xét nghiệm thalassemia), không phù hợp với kịch bản sàng lọc ban đầu tại phòng khám.

2.2.3. Phân tích Tương quan (Correlation Analysis)

Nhóm sử dụng heatmap Pearson để đánh giá mức độ tương quan giữa các biến.

Bảng 2.3-Tổng hợp các đặc trưng tương quan mạnh nhất với biến mục tiêu ($|r| > 0.3$):

Đặc trưng	Hệ số tương quan	Ý nghĩa lâm sàng
ca	+0.46	Số mạch vành bị tắc càng nhiều → nguy cơ bệnh càng cao
thalch	-0.39	Nhịp tim tối đa càng thấp → nguy cơ bệnh càng cao
oldpeak	+0.39	ST depression càng cao → nguy cơ bệnh càng cao
cp	-0.39	Loại đau ngực liên quan rõ đến bệnh tim

exang	+0.35	Đau ngực khi gắng sức là dấu hiệu rõ của bệnh tim
sex	+0.31	Giới tính có ảnh hưởng đến nguy cơ bệnh tim

2.2.4. Phân tích Phân phối và Outlier

Nhóm sử dụng biểu đồ KDE (Kernel Density Estimation) để so sánh phân phối giữa nhóm có bệnh và không có bệnh. Kết quả nổi bật:

- thalach (nhịp tim tối đa): Đặc trưng có giá trị phân loại cao nhất. Nhóm không bệnh tập trung ở 150–165 bpm; nhóm có bệnh ở 120–135 bpm – hai nhóm tách biệt rõ ràng.
- oldpeak: Nhóm không bệnh tập trung tại 0; nhóm có bệnh trải rộng đến 4+, cho thấy giá trị phân loại cao.
- age: Nhóm không bệnh tập trung ở 40–55 tuổi; nhóm có bệnh ở 55–60 tuổi.
- trestbps và chol: Hai nhóm gần như chồng lên nhau → giá trị phân loại yếu.

Phân tích outlier bằng phương pháp IQR phát hiện các giá trị 0 trong cột trestbps và chol – không hợp lý về mặt sinh học (huyết áp và cholesterol không thể bằng 0). Các giá trị này được xử lý như missing values trong bước tiền xử lý.

2.3. Tiền xử lý Dữ liệu (Preprocessing)

2.3.1. Chiến lược Tiền xử lý

Dựa trên kết quả EDA, nhóm thiết lập chiến lược tiền xử lý toàn diện:

- Xử lý lỗi dữ liệu: Chuyển giá trị 0 bất khả thi lâm sàng (trestbps, chol) thành NaN bằng OutlierHandler tùy chỉnh.

- Loại bỏ cột không cần thiết: id, dataset, num (cột gốc target), ca, thal – để tránh data leakage và xét nghiệm chuyên sâu không thực tế.
- Điền khuyết biến số: Dùng Median (trung vị) vì dữ liệu có phân phối lệch và outlier.
- Điền khuyết biến phân loại: Dùng Mode (giá trị xuất hiện nhiều nhất) để duy trì cấu trúc phân phối.
- Chuẩn hóa biến số: StandardScaler để các mô hình nhạy cảm với khoảng cách (LR, SVM) hoạt động hiệu quả.
- Mã hóa biến phân loại: OneHotEncoder(handle_unknown='ignore') để xử lý nhãn mới khi triển khai thực tế.

2.3.2. Chia tập Train/Test

Nhóm chia dữ liệu theo tỷ lệ 80/20 với stratify=y để đảm bảo tỷ lệ lớp nhất quán giữa hai tập. Kết quả: X_train (736 mẫu) và X_test (184 mẫu).

2.3.3. Kiến trúc Pipeline scikit-learn

Toàn bộ quy trình tiền xử lý được đóng gói trong một Pipeline scikit-learn hoàn chỉnh, đảm bảo chống data leakage và dễ dàng triển khai:

Bảng 2.4 - Quy trình tiền xử lý

Bước	Thành phần	Mô tả
1	OutlierHandler	Chuyển giá trị 0 bất hợp lý thành NaN (trestbps, chol)
2	FeatureEngineer	Tạo 2 đặc trưng mới: heart_rate_ratio, age_risk_group
3	ColumnTransformer	Phân luồng xử lý riêng cho biến số và biến phân loại

3a	└─ num_pipeline	SimpleImputer(median) → StandardScaler
3b	└─ cat_pipeline	SimpleImputer(most_frequent) → OneHotEncoder
4	Classifier	Mô hình phân loại (Random Forest sau khi chọn)

2.4. Feature Engineering

2.4.1. Đặc trưng 1: heart_rate_ratio – Tỷ lệ Nhịp tim đạt được

Dựa trên công thức Karvonen trong y học: nhịp tim tối đa lý thuyết = $220 - \text{tuổi}$. Tỷ lệ nhịp tim đạt được được tính bằng $\text{thalach} / (220 - \text{age})$. Đây là chỉ số đo mức độ đáp ứng tim mạch trong stress test.

Ý nghĩa lâm sàng: Bệnh nhân đạt $< 85\%$ ngưỡng tối đa trong stress test có nguy cơ bệnh tim cao hơn đáng kể – hiện tượng 'chronotropic incompetence'. Feature mới bắt được sự phụ thuộc phi tuyến giữa nhịp tim và tuổi mà biến thalach đơn thuần không nắm được.

2.4.2. Đặc trưng 2: age_risk_group – Nhóm Nguy cơ theo Tuổi

Nguy cơ bệnh tim mạch không tăng tuyến tính theo tuổi, mà tăng vọt tại các ngưỡng nhất định sau 40, 50 và 60 tuổi (threshold effect). Nhóm phân chia tuổi thành 4 mức: 0 (0–40 tuổi), 1 (40–50 tuổi), 2 (50–60 tuổi), 3 (60+ tuổi).

Ý nghĩa lâm sàng: Tỷ lệ mắc bệnh tăng từ 34.4% (nhóm 0) lên 72.9% (nhóm 3), phản ánh chính xác quy luật sinh học về nguy cơ tim mạch theo độ tuổi.

2.4.3. Đánh giá hiệu quả Feature Engineering

Kết quả kiểm chứng chéo 5-fold với Logistic Regression: F1-Score tăng từ 0.8174 (baseline) lên 0.8250 (sau FE), cải thiện +0.92%. Điều này chứng minh hai đặc trưng mới mang lại giá trị dự đoán thực sự.

2.5. Mô hình Machine Learning

Nhóm xây dựng và so sánh 3 mô hình thuộc các nhóm thuật toán khác nhau, đảm bảo tính đa dạng và toàn diện trong so sánh:

2.5.1. Logistic Regression (Mô hình 1)

Logistic Regression là mô hình tuyến tính cơ bản, hoạt động bằng cách ước lượng xác suất xảy ra của sự kiện thông qua hàm sigmoid. Nhóm sử dụng `class_weight='balanced'` để xử lý mất cân bằng tiềm năng và `max_iter=1000` để đảm bảo hội tụ. GridSearchCV dò tìm tham số C và penalty trên 2 nhóm solver (liblinear và lbfgs).

Ưu điểm: Minh bạch, có thể giải thích trọng số từng đặc trưng – quan trọng trong y tế. Tham số tối ưu: `C=10`, `penalty='l2'`, `solver='lbfgs'` (điều chuẩn L2 tự động loại bỏ đặc trưng nhiễu).

2.5.2. Random Forest (Mô hình 2)

Random Forest là mô hình ensemble kết hợp nhiều Decision Tree, tạo tính ngẫu nhiên qua bootstrap sampling (mỗi cây học trên tập con dữ liệu khác nhau) và feature subsampling (mỗi lần split chỉ chọn tập con đặc trưng). Nhóm thực hiện 3 kịch bản thực nghiệm trên wandb: Baseline, GridSearchCV và ExtraConfig.

Tham số tối ưu từ GridSearchCV :

`n_estimators=100`, `max_depth=10`, `min_samples_split=5`,
`class_weight='balanced'`.

2.5.3. Support Vector Machine (Mô hình 3)

SVM tìm siêu phẳng phân cách tối ưu cực đại hóa margin giữa hai lớp. Nhóm sử dụng kernel RBF để xử lý mối quan hệ phi tuyến giữa các chỉ số lâm sàng. GridSearchCV dò tìm C trong [0.1, 1, 10, 100] và gamma trong ['scale', 'auto'].

2.6. Theo dõi Thực nghiệm với Weights & Biases (wandb)

Toàn bộ thực nghiệm được theo dõi tự động qua wandb tại project 'heart-disease-classification'. Nhóm thực hiện tổng cộng hơn 5 runs với cấu hình khác nhau, log đầy đủ: hyperparameters, metrics (Recall, Precision, F1, AUC), confusion matrix, ROC curve và PR curve.

Link wandb: <https://wandb.ai/phat-05/heart-disease-classification>

CHƯƠNG 3: KẾT QUẢ THỰC NGHIỆM

3.1. Kết quả từng Mô hình

3.1.1. Logistic Regression

Sau GridSearchCV với tham số $C=10$, $\text{penalty}='l2'$, $\text{solver}='lbfgs'$ và ngưỡng phân loại 0.4, mô hình đạt:

Bảng 3.1- Kết quả mô hình Logistic Regression với GridSearchCV

Metric	Giá trị
Recall	0.8627
Precision	0.7788
F1-Score	0.8186
AUC	0.9051
CV Recall (5-Fold)	~0.820

Nhận xét: Mô hình đạt nền tảng tốt với Recall 86.27%, chỉ bỏ sót 14 bệnh nhân trong 184 ca test. Đây là baseline tốt cho bài toán y tế.

3.1.2. Random Forest – So sánh 3 Kịch bản

Bảng 3.2 – So sánh 3 kịch bản Random Forest (Threshold = 0.4):

Kịch bản	Recall	Precision	F1-Score	AUC
Baseline (Mặc định)	0.9216	0.7769	0.8430	–
GridSearch CV (Tối ưu)	0.9412	0.7805	0.8533	0.9042
ExtraConfig (300 cây, sâu tự do)	0.9314	0.7787	0.8482	–

Kết quả nổi bật: Kịch bản GridSearchCV cho kết quả tốt nhất ở cả Recall (0.9412) và F1 (0.8533), chứng minh hiệu quả của tối ưu hóa siêu tham số. ExtraConfig với mô hình phức tạp hơn không cải thiện được kết quả – minh họa nguyên lý Diminishing Returns trong hyperparameter tuning.


3.1.3. Support Vector Machine

Bảng 3.3 - SVM với RBF kernel sau GridSearchCV đạt:

Metric	Giá trị
Recall	0.9314
Precision	0.7787

F1-Score	0.8482
AUC	~0.897

3.2. So sánh Tổng thể Các Mô hình



3.1. So sánh tổng thể các mô hình

Bảng 3.4 – Bảng so sánh hiệu năng tổng hợp (Threshold = 0.4):

Mô hình	Recall ↑	Precision	F1-Score	AUC ↑
Logistic Regression	0.8627	0.7788	0.8186	0.9051
SVM (RBF Kernel)	0.9314	0.7787	0.8482	~0.897
Random Forest (GridSearchCV)	0.9412	0.7805	0.8533	0.9042


Random Forest (GridSearchCV) là mô hình được chọn để triển khai

Phân tích chi tiết:

- Recall (ưu tiên hàng đầu): Random Forest đạt 0.9412 – cao nhất, chỉ bỏ sót ~6% ca bệnh (≈ 11 bệnh nhân trong 184 test).
- AUC: Random Forest (0.9042) cho thấy khả năng phân biệt tốt ở mọi ngưỡng, vượt AUC = 0.9 – ngưỡng xuất sắc trong y học lâm sàng.
- F1-Score: Random Forest đạt cân bằng tốt nhất (0.8533), đảm bảo mô hình không bị lệch hoàn toàn về một phía.
- Kết luận: Random Forest (GridSearchCV) là lựa chọn tối ưu để triển khai thực tế.

3.3. Đường cong ROC và Feature Importance

3.3.1. Phân tích ROC Curve



3.2. Phân tích ROC Curve

Cả 3 mô hình đều có đường cong ROC nằm xa đường tham chiếu (Random guess, AUC = 0.5), cho thấy năng lực phân loại tốt. Random Forest có AUC cao nhất và đường ROC áp sát góc trên bên trái – đặc điểm của mô hình tốt. Biểu đồ ROC cho

thấy tại ngưỡng False Positive Rate = 0.1, Random Forest đạt True Positive Rate $\approx$ 0.85, vượt trội hơn hai mô hình còn lại.

3.3.2. Feature Importance (Random Forest)

Bảng 3.5-Top 5 đặc trưng quan trọng nhất theo Random Forest:

Hạng	Đặc trưng	Importance	Ý nghĩa y học
1	cp_asymptomatic	~ 0.0896	Đau ngực không triệu chứng – liên quan trực tiếp đến bệnh tim
2	oldpeak	~ 0.085	ST depression – chỉ số gắng sức quan trọng
3	heart_rate_ratio	~ 0.078	FE mới – tỷ lệ nhịp tim theo ngưỡng tuổi
4	age	~ 0.072	Tuổi tác – yếu tố nguy cơ nền tảng
5	thalch	~ 0.068	Nhịp tim tối đa – phân biệt tốt hai nhóm

- heart_rate_ratio nằm trong top 3 – xác nhận giá trị của Feature Engineering.
- age_risk_group cũng đóng góp tích cực ở vị trí trung bình, chứng minh việc phân nhóm tuổi giúp mô hình nắm bắt được threshold effect.

3.4. Model Persistence

Mô hình tốt nhất (Random Forest + full pipeline) được đóng gói thành file model_package.pkl qua joblib với cấu trúc:

Bảng 3.6 - Model Persistence

Thành phần	Nội dung
pipeline	Full sklearn Pipeline (OutlierHandler → FeatureEngineer → ColumnTransformer → RF Classifier)
metadata.version	2.0
metadata.train_date	Ngày huấn luyện (tự động ghi nhận)
metadata.features_in	Danh sách 11 đặc trưng đầu vào từ X_train.columns
metadata.optimal_threshold	0.4 (ngưỡng phân loại tối ưu)
metadata.metrics	Recall=0.9412, Precision=0.7805, F1=0.8533, AUC=0.9042

CHƯƠNG 4: ỨNG DỤNG THỰC TẾ

4.1. Kiến trúc Hệ thống

Hệ thống được xây dựng theo kiến trúc 3 lớp: Frontend (ReactJS) ↔ Backend API (Flask/Python) ↔ AI Model + Database (MySQL). Luồng xử lý:

1. Người dùng nhập 11 chỉ số lâm sàng vào form ReactJS.
2. Frontend gọi API POST /predict với JSON payload.
3. Backend (Flask) nhận dữ liệu, lưu vào MySQL (bảng BenhNhan, ThongSoYTe).
4. Backend load model_package.pkl, chạy pipeline.predict_proba().
5. Backend tính risk_level từ xác suất và ngưỡng 0.4, lưu vào KetQuaChuanDoan.
6. Kết quả trả về JSON: prediction, probability, risk_level.

7. ReactJS hiển thị kết quả với màu sắc trực quan (xanh/vàng/đỏ theo mức nguy cơ).

4.2. Cơ sở Dữ liệu MySQL

Database gồm 3 bảng chính:

- `benh_nhan`: Lưu thông tin cá nhân bệnh nhân (`ho_ten`, `tuoi`, `gioi_tinh`, `cccd`). Hỗ trợ tái sử dụng thông tin khi một bệnh nhân khám nhiều lần.
- `thong_so_y_te`: Lưu 11 chỉ số lâm sàng của mỗi lần khám (`trestbps`, `chol`, `cp`, `thalch`...) kèm timestamp.
- `ket_qua_chuan_doan`: Lưu kết quả AI (`ket_qua`, `xac_suat`, `muc_do_rui_ro`) liên kết với `thong_so_y_te`.

4.3. API Endpoints

Bảng 4.1- API Endpoints

Method	Endpoint	Chức năng	Mô tả
GET	/	Health check	Kiểm tra API đang hoạt động
POST	/predict	Dự đoán	Nhận JSON chỉ số lâm sàng, trả về kết quả AI + lưu DB
GET	/history	Lịch sử	Trả về danh sách tất cả ca chẩn đoán đã lưu trong DB

4.4. Kịch bản Sử dụng Thực tế

4.4.1. Kịch bản 1: Sàng lọc tại Phòng khám Đa khoa

Bác sĩ tổng quát tiếp nhận bệnh nhân đến khám sức khỏe định kỳ. Sau khi đo các chỉ số cơ bản (huyết áp, cholesterol, nhịp tim...), bác sĩ nhập vào hệ thống. AI phân tích trong vài giây và đưa ra mức nguy cơ:

- Nguy cơ Thấp (xác suất < 0.2): Bệnh nhân được tư vấn duy trì lối sống lành mạnh.
- Nguy cơ Trung bình (0.2–0.4): Bệnh nhân được lên lịch tái khám sau 3 tháng.
- Nguy cơ Cao (0.4–0.8): Bệnh nhân được giới thiệu làm thêm ECG và xét nghiệm chuyên sâu.
- Nguy cơ Rất cao (> 0.8): Bệnh nhân được giới thiệu ngay đến khoa Tim mạch.

4.4.2. Kịch bản 2: Theo dõi Bệnh nhân Tim mạch Mãn tính

Bệnh nhân đã có tiền sử bệnh tim tái khám định kỳ. Hệ thống lưu lịch sử chỉ số qua các lần khám (thông qua CCCD). Bác sĩ xem được xu hướng thay đổi xác suất nguy cơ theo thời gian để điều chỉnh phác đồ điều trị phù hợp.

4.5. Hạn chế và Rủi ro khi Triển khai

- Hệ thống hỗ trợ quyết định (CDSS), không thay thế bác sĩ: Kết quả AI chỉ là công cụ sàng lọc ban đầu; chẩn đoán cuối cùng phải do bác sĩ có chuyên môn quyết định sau khi xem xét toàn diện.
- Tỷ lệ báo động giả (False Positive ~22%): Do tối ưu Recall, mô hình có xu hướng cảnh báo nhiều hơn. Điều này dẫn đến một số bệnh nhân khỏe mạnh bị đề nghị xét nghiệm thêm – tạo áp lực không cần thiết và chi phí y tế bổ sung.
- Giới hạn dữ liệu: Dataset từ 4 bệnh viện Mỹ và Châu Âu có thể không đại diện cho quần thể bệnh nhân Việt Nam do khác biệt về di truyền, chế độ ăn uống và lối sống.
- Bảo mật và quyền riêng tư: Dữ liệu y tế cần được bảo vệ theo tiêu chuẩn HIPAA/GDPR. Hiện tại hệ thống demo chưa có cơ chế xác thực và mã hóa dữ liệu hoàn chỉnh.
- Độ trôi dạt mô hình (Model Drift): Khi triển khai thực tế lâu dài, phân phối dữ liệu có thể thay đổi theo thời gian, đòi hỏi phải tái huấn luyện mô hình định kỳ.

4.6. Video thực hiện demo project

https://drive.google.com/file/d/1ZzNAxLLmfliqh8Va2H_GUfidvHUw1nll/view?usp=sharing

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Tổng kết Đóng góp

Đồ án đã hoàn thành thành công mục tiêu xây dựng hệ thống phân loại bệnh tim mạch end-to-end với những đóng góp chính:

- Quy trình ML hoàn chỉnh: EDA toàn diện (9+ biểu đồ), tiền xử lý có hệ thống, feature engineering y học có căn cứ, training và so sánh 3 mô hình với GridSearchCV và 5-fold CV.
- Mô hình hiệu suất cao: Random Forest đạt Recall = 0.9412 và AUC = 0.9042 – vượt ngưỡng xuất sắc trong y học lâm sàng.
- Feature Engineering giá trị: heart_rate_ratio và age_risk_group được chứng minh cải thiện hiệu suất và nằm trong top feature importance.
- Hệ thống triển khai hoàn chỉnh: Full pipeline (ReactJS ↔ Flask ↔ MySQL ↔ AI) hoạt động end-to-end, hỗ trợ lịch sử chẩn đoán và phân mức nguy cơ 4 cấp.
- Theo dõi thực nghiệm có hệ thống: Wandb với 5+ runs, log đầy đủ metrics, charts, artifacts.

5.2. Hạn chế

- Chưa có cơ chế xác thực người dùng và phân quyền (bác sĩ/bệnh nhân).
- Chưa có chức năng dự đoán theo lô (batch prediction) cho nhiều bệnh nhân cùng lúc.
- Dataset chưa đại diện cho quần thể bệnh nhân Việt Nam.
- Chưa có learning curves và phân tích overfitting/underfitting đầy đủ trong báo cáo.

5.3. Hướng Phát triển

- Mở rộng dataset: Thu thập thêm dữ liệu lâm sàng từ bệnh viện Việt Nam để nâng cao tính đại diện.
- Tích hợp SHAP: Giải thích kết quả dự đoán cho từng bệnh nhân cụ thể (XAI – Explainable AI), giúp bác sĩ hiểu lý do mô hình đưa ra cảnh báo.
- Model Monitoring: Thiết lập hệ thống giám sát độ trôi dạt mô hình và tự động cảnh báo khi cần tái huấn luyện.
- Tích hợp Deep Learning: Thử nghiệm Neural Networks hoặc Gradient Boosting (XGBoost, LightGBM) để cải thiện thêm hiệu suất.
- Bảo mật dữ liệu: Triển khai JWT authentication, HTTPS và mã hóa dữ liệu y tế theo tiêu chuẩn quốc tế.
- Mobile App: Phát triển ứng dụng di động để hỗ trợ bác sĩ tại phòng khám nhỏ hoặc vùng xa.

TÀI LIỆU THAM KHẢO

- [1] Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.). O'Reilly Media.
- [2] UCI Machine Learning Repository – Heart Disease Dataset. <https://archive.ics.uci.edu/dataset/45/heart+disease>
- [3] Scikit-learn Documentation. <https://scikit-learn.org/stable/>
- [4] Weights & Biases Documentation. <https://docs.wandb.ai/>
- [5] React Documentation. <https://react.dev/>
- [6] Flask Documentation. <https://flask.palletsprojects.com/>
- [7] World Health Organization (2023). Cardiovascular diseases (CVDs). [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))

- [8] Detrano, R., et al. (1989). International application of a new probability algorithm for the diagnosis of coronary artery disease. *American Journal of Cardiology*, 64(5), 304–310.
- [9] Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1988). Heart Disease Dataset. UCI Machine Learning Repository.
- [10] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [11] Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.
- [12] Cox, D. R. (1958). The regression analysis of binary sequences. *Journal of the Royal Statistical Society, Series B*, 20(2), 215–242.